

Machine Learning und tiefe neuronale Netze mit TensorFlow

DAVID BAUMGARTNER



BACHELORARBEIT

Nr. XXXXXXXXXXXX-A

eingereicht am
Fachhochschul-Bachelorstudiengang

Software Engineering

in Hagenberg

im Januar 2017

Diese Arbeit entstand im Rahmen des Gegenstands

.....

im

Wintersemester 2016/17

Betreuer:

Stephan Dreiseitl, FH-Prof. PD DI Dr.

Erklärung

Ich erkläre eidesstattlich, dass ich die vorliegende Arbeit selbstständig und ohne fremde Hilfe verfasst, andere als die angegebenen Quellen nicht benutzt und die den benutzten Quellen entnommenen Stellen als solche gekennzeichnet habe. Die Arbeit wurde bisher in gleicher oder ähnlicher Form keiner anderen Prüfungsbehörde vorgelegt.

Hagenberg, am 14. Januar 2017

David Baumgartner

Inhaltsverzeichnis

Erklärung	iii
Vorwort	vi
Kurzfassung	vii
Abstract	viii
1 Einleitung	1
1.1 Hintergrund	1
1.2 Motivation	1
1.3 Zielsetzung	1
2 Begriffe im Maschinellen Lernen	2
2.1 Data Science	2
2.2 Machine Intelligence	3
2.3 Machine Learning	3
2.4 Neuronale Netzwerke	3
2.5 Neuron	4
2.6 Ebenen/Layer	5
2.7 Informationen Merken und Wiedererkennung	6
2.8 Konvergieren im Maschinellen Lernen	6
2.9 Backpropagation	6
2.10 Allgemeine Probleme	7
2.11 Trainieren	8
2.12 Domänenklassen	8
2.12.1 Clustering	8
2.12.2 Regression	9
2.12.3 Klassifikation	9
2.12.4 Predict	9
2.12.5 Robotics	9
2.12.6 Computer Vision	10
2.12.7 Optimierung	10
2.13 Neuronale Netzwerktypen	10

2.13.1	FeedForward	10
2.13.2	Self-Organizing Map	11
2.13.3	Hopfield Neuronal Network	11
2.13.4	Boltzmann Machine	11
2.13.5	Deep FeedForward	12
2.13.6	NEAT	12
2.13.7	Convolutional Neural Network	12
2.13.8	Recurrent Network	13
2.14	Domänen und Typen Matrix	13
2.15	Optimierung	14
3	TensorFlow	17
3.0.1	Graphs/Dataflowgraph	18
3.0.2	Operation	19
3.0.3	Sessions	19
3.0.4	Tensor	19
3.0.5	Hyperparameter	19
3.1	Bibliotheksinhalt	20
3.1.1	Datentypen	20
3.1.2	Operationen	20
3.1.3	TensorBoard	30
4	Facial Keypoints Detection	35
4.1	Ausgangssituation	35
4.2	Vorbereitung	35
4.2.1	Daten vorbereiten und normalisieren	35
4.2.2	Evaluation- und Errorfunktion	35
4.3	Neuronale Ebenen vorbereiten	35
4.4	Neuronale Ebenen verknüpfen	35
4.5	Trainieren	35
4.6	Validierungsergebnisse	35
	Quellenverzeichnis	36
	Literatur	36

Vorwort

Kurzfassung

Abstract

Kapitel 1

Einleitung

Hintergrund - Motivation - Zielsetzung
Warum - wieso - weshalb?

1.1 Hintergrund

1.2 Motivation

1.3 Zielsetzung

Kapitel 2

Begriffe im Maschinellen Lernen

Diese Erklärung der Begriffe und Elemente verfolgt zwei Ziele. Zum Einen stellt dies Grundlage des gesamten Themas dar und soll für Interessierte, die nicht so vertraut sind, eine Einführung in die Thematik bieten. Und zum Anderen werden viele dieser Begriffe erläutert, welche noch häufig zum Einsatz kommen (u.A. Neuron, Aktivierungsfunktion, ...).

2.1 Data Science

Data Science wird generell als die Extraktion von Wissen aus Daten bezeichnet. Dabei werden die Fachbereiche Statistik und Mathematik, Informatik und Machine Learning sowie einige weitere, mit diesem Begriff zusammengefasst. Das Gebiet für sich wird auch als Berufstätigkeit bezeichnet, wobei meist spezialisierte Formen für die Berufsbezeichnung verwendet werden.

Damit Wissen aus Daten überhaupt extrahiert werden kann, muss ein ganzer Prozess durchlaufen werden. Dieser beginnt mit dem Zusammentragen von Rohdaten aus der Realität, welche zu diesem Zeitpunkt noch keinen Zusammenhang offenbaren. Im zweiten Prozessschritt werden diese Daten meist umgebaut und neu sortiert, wobei dieser Schritt nicht immer erforderlich ist. Auf die zurecht gelegten Daten besteht nun die Möglichkeit Modelle, Algorithmen sowie weitere Extraktionen durchzuführen. Die erneut extrahierten Daten werden in weiterer Folge als Ausgangsdaten verwendet. Auf diese Daten ausgeführte Modelle und Algorithmen liefern Ergebnisse, die visuell dargestellt für eine größer Gruppe von Personen geeignet sind. Aus diesem gelernten Wissen besteht zusätzlich die Möglichkeit dieses zum Generieren von neuen Daten zu verwenden und neue Modelle zu entwickeln, die zum Beispiel Vorgänge in der Natur noch akkurater widerspiegeln.

2.2 Machine Intelligence

Machine Intelligence ist ein Begriff, der in dieser Form noch nicht definiert worden ist. Einige namhafte Unternehmen wie Google Inc. und Microsoft Corporation bieten jeweils unterschiedliche Definitionen oder Beschreibungen. Die Definitionen dieser Firmen weichten nur unwesentlich voneinander ab. Dieser Begriff wird als Überbegriff über das gesamte Gebiet mit Machine Learning, Künstlicher Intelligenz, Konversationsintelligenz und alle Themen die in näherer Beziehung dazu stehen verwendet.

2.3 Machine Learning

Machine Learning definiert eine große Anzahl an Theorien und Umsetzungen von nicht explizit programmierten Abläufen. Diese wurden aus Studien in den Bereichen der Mustererkennung und der rechnerischen Lerntheorie mit Künstlicher Intelligenz teilweise entwickelt. Dieses Gebiet umfasste im Jahr 2016 aber sehr viel mehr. So existieren zusätzliche Ansätze aus dem Bereich der Biologie wie zum Beispiel Neuronale Netzwerke, die dem Gehirn nachempfunden sind und genetische Algorithmen, die der Weiterentwicklung eines Lebewesens ähneln. Ein ganz anderer Zugang wurde in der Sowjetunion verfolgt, mit sogenannten 'Support Vektor Machines', bei welchem man einen rein mathematischen Ansatz anstrebt. [4]

2.4 Neuronale Netzwerke

Neuronale Netzwerke sind seit dem Jahr 2016 auch bekannt unter dem Begriff 'Deep Learning'.

Die Theorie und die ersten Grundlagen wurden im Jahre 1943 von Warren McCulloch und Walter Pitts geschaffen, die ein Modell entwickelten, jedoch nicht die technischen Möglichkeiten hatten dieses umzusetzen. Dieses führte zur 'Threshold Logik'. Durch den Grundstein des 'Backpropagation'-Algorithmus im Jahre 1975 ist es möglich, Netzwerke mit mehr als drei Ebenen zu trainieren.

Neuronale Netzwerke bestehen aus Neuronen, die miteinander verbunden sind und gemeinsam ein Netzwerk ergeben. Die Verbindungen sind nicht fest vorgegeben, sondern können auch zum Beispiel Schleifen bilden.

[3]




Abbildung 2.1: Neuron mit Eingang, Kernfunktion, Aktivierungsfunktion

2.5 Neuron

Ein Neuron wurde einer Nervenzelle in einem Gehirn nachempfunden mit den folgenden Bestandteilen:

Informationseingangsstrom ist der Dateneingang, wobei ein Neuron ein bis theoretisch beliebig viele solcher Eingänge haben kann. Dies hängt von der jeweiligen Architektur des Netzwerks ab.

Informationsgewichtung bezeichnet die Gewichtung mit der der Eingangsstrom gewertet wird. So wird ein Informationseingangsstrom mehr oder weniger berücksichtigt. Diese Gewichtung wird durch den Backpropagation-Algorithmus angepasst und nachjustiert.

Kernfunktion bewirkt das Verarbeiten der gewichteten Informationseingänge. Im einfachsten Fall werden alle Werte aufsummiert. Es wäre aber möglich, jegliche Berechnung hier einfließen zu lassen, welche mehrere Werte verwendet und daraus einen neuen Wert berechnet.

Aktivierungsfunktion berechnet den Ausgang eines Neurons. Dabei wird eine weitere Funktion auf das im Kern berechnete Ergebnis ausgeführt und führt dazu, dass ein Ergebnis noch stärker ausgeprägt weitergegeben wird oder minimiert wird. Diese Aktivierungsfunktion ist meist die Sigmoid-Funktion oder eine lineare Funktion.

TODO FORMAT Diagramm

Die einfachste Repräsentation eines Neurons lässt sich mathematisch folgendermaßen darstellen. Im Kern wird eine Summenberechnung durchgeführt. Dabei werden die Eingangswerte und deren Gewichtung miteinander multipliziert, sowie diese Ergebnisse aufsummiert. Der griechische Buchstabe ϕ (phi) steht für die Aktivierungsfunktion des Neurons und stellt damit die Ausgabe des Neurons dar.

$$f(x, w) := \phi\left(\sum_i w_i * x_i\right) \quad (2.1)$$



Abbildung 2.2: Basisaktivierungsfunktionen

Bias Neuron definiert einen Spezialfall eines Neurons, welches keine Dateneingänge somit auch keine Gewichtung hat und keine Berechnung im Kern durchführt. Dieses liefert nur einen konstanten Wert, wie zum Beispiel eine 1. Durch die konstante Auslieferung wird auch die Aktivierungsfunktion überflüssig. Das Bias Neuron stellt somit einen stetigen Wert für das Netzwerk dar, beziehungsweise für die darauffolgende Ebene.

2.6 Ebenen/Layer

Ebenen sind Zusammenschlüsse von Neuronen, welche sich auf der selben Stufe befinden. Diese Neuronen sind aber nicht miteinander verbunden, sondern bekommen Daten aus der Ebene davor und geben diese an die darauffolgende Ebene weiter. Dieser Typ wird **Hiddenlayer** bezeichnet. Jedes Netzwerk benötigt zusätzlich zwei weitere Ausprägungen an Ebenen. Diese sind:

Inputlayer stellt den Übergang zwischen der Welt außerhalb des Neuronalen Netzwerks und dem Netzwerk dar. Diese Ebene nimmt die Daten ohne Gewichtung auf und gibt sie an die darauffolgende Ebene weiter.

Outputlayer befindet sich am Ende eines Netzwerkes. Dieser Layer hat die Aufgabe, die Daten nach außen weiterzugeben, anstatt an das darauffolgende Netzwerk. Hierbei werden die Informationen meist nur mehr für die Ausgabe aufbereitet. In manchen Netzwerken existieren keine Outputlayer in diesem Sinne, sondern ein Layer, der als Hiddenlayer und Outputlayer fungiert. Dies ist der Fall, wenn nur zwei Layer sich im Netzwerk befinden




Abbildung 2.3: Einfaches Neuronales FeedForward Netzwerk

und einer davon vom Inputlayer eingenommen wird.

2.7 Informationen Merken und Wiedererkennung

Durch das Anpassen der Gewichtungen bei jedem Dateneingangsstrom mit Hilfe des Backpropagation-Algorithmus ist es möglich, Zustände zu speichern und diese auch zu merken. Sollte ein ähnlicher Dateneingang stattfinden, wo zuvor schon einer einmal vorhanden war, dann sollte dieser ähnlich behandelt werden. Dieser kann möglicherweise zu derselben Kategorie gehören, wie der zuvor schon bekannte gemachte und gelernte Dateneingang.

2.8 Konvergieren im Maschinellen Lernen

Konvergieren im Maschinellen Lernen bezeichnet das Minimieren der Fehlerquote gegen 0. Die Fehlerquote wird dabei als Error bezeichnet und ist ausschlaggebend für den Lernprozess. Eine Error von 0 würde bedeuten, dass das Netzwerk keinen Fehler machen würde. Für die Feststellung des Fehlers gibt es diverse Funktionen wie zum Beispiel die 'Mean-Square-Error'-Methode.

2.9 Backpropagation

Bis zum Jahre 1986 gab es keine automatisierte Möglichkeit, die Gewichtungen in einem Netzwerk anzupassen. In diesem Jahre entwickelten Rumelhart, Hinton & Williams eine mögliche Lösung, welche sehr ähnlich zu anderen Ansätzen von früher war (Werbos, 1974; Parker, 1985; Cun, 1985). Die zentrale Idee in ihrer Lösung liegt darin, die Abweichung des produzierten Ergebnisses zum wirklichen erwarteten Ergebnis zu bestimmen. Aufgrund dieses Fehlers lassen sich im Anschluss die Gewichtungen im Netzwerk vom Ende zum Anfang nachjustieren. Diese Technik ermöglichte damit tiefe Netzwerke zu konstruieren und auch zu trainieren.

Lernrate skaliert die Steigung des Lernprozesses, mit der Auswirkung ob schneller oder langsamer gelernt wird. Eine Lernrate unter 0 würde die Lerngeschwindigkeit stark verlangsamen. Ein Wert über 1 würde eine hohe Lerngeschwindigkeit zur Folge haben. Eine zu hohe Rate würde nicht zum Konvergieren (2.8) führen, sondern zum Springen.

Momentum stellt wie die Lernrate eine Skalierung des Lernprozesses dar. Dabei werden mit dem Faktor die früheren Gewichtsupdates berücksichtigt. Dies führt dazu, dass lokale Tiefpunkte überwunden werden können und das System doch zum globalen Tiefpunkt konvergiert.

2.10 Allgemeine Probleme

Nach dem aktuellen Stand der Dinge können Neuronale Netzwerke nicht jede Frage dieser Welt beantworten. Das Entwickeln eines neuen Netzwerks ist eine sehr schwierige und eine lang andauernde Aufgabe. Dabei können Fehler auftreten, welche natürlicher Natur sein können, aber auch durch den Entwickler verursacht sein können.

Diese Arbeit wird auf die bekanntesten Probleme eingehen und auch Lösungen oder mögliche Lösungsansätze beinhalten.

Overfitting bezeichnet ein Problem, welches nicht nur Machine Learning betrifft, sondern auch Menschen und andere Lebewesen. Ein Student lernt zum Beispiel auf eine Prüfung und ist im Besitz einer Klausur aus einem Vorjahr. Nach öfterem Durchspielen der Fragen und sich selbst testen, befindet er sich in der Lage diese Klausur mit einer sehr hohen Wahrscheinlichkeit zu bestehen. Dabei hat sich die Klausur in seinem Gehirn eingepreßt, aber nicht das Stoffgebiet zu welchem er eine Klausur schreiben muss. Das Problem wird als Overfitting bezeichnet und beschreibt, dass etwas gemerkt wurde, aber nicht gelernt worden ist und somit eine Abwandlung von Informationen nicht wiedererkannt werden.

Daten die zum Trainieren von Netzwerken verwendet werden, stellen selbst Probleme dar. Eine zu geringe Menge an Daten stellt den Entwickler vor das Problem, dass er für diese Daten ein akkurates Netzwerk entwickeln kann. Dieses Netzwerk würde aber möglicherweise nicht die gewünschten Resultate liefern, da die zur Verfügung gestellten Daten nur einen kleinen Teil des Gesamten repräsentieren. Zusätzlich kann es sein, dass die zur Verfügung gestellten Daten selbst nicht vollständig sind und somit wieder nur ein Subset verwendet werden kann.

Datensätze können ähnlich sein zu anderen, sind aber trotzdem wieder einzigartig. Dies bedeutet, dass ein Netzwerk, welches für eine Problemstellung entwickelt und trainiert wurde, nicht eins zu eins übernommen werden kann. Für diese Daten muss wieder ein Netzwerk entwickelt werden.

2.11 Trainieren

Überwachtes Trainieren definiert, dass die Daten welche zur Verfügung stehen aus zwei Teilen bestehen. Erstens aus den Daten selbst, aus welchen gelernt und verstanden werden soll. Zweitens aus den Ergebnissen zu welchem das Netzwerk kommen sollte. Der bekannte Wert wird meistens als Label bezeichnet. In diese Situation liefert das Netzwerk ein Ergebnis, welches mit dem erwarteten Wert verglichen werden kann. Dieser Unterschied wird zum Feststellen des Fehlers verwendet, welcher besagt wie inkorrekt das Ergebnis ist. Des Weiteren wird dieser Fehlerwert für die Backpropagation (2.9) benötigt.

Unüberwachtes Trainieren kommt dann zu tragen, wenn nur Daten zum Trainieren zur Verfügung stehen. Der erwartete Ausgang ist unbekannt. Diese Strategie wird in Fällen von Clustering (2.12.1) verwendet. Dabei sollen nicht bekannte Gruppen von zusammengehörenden Beispielen identifiziert werden. Self-Organizing Maps (2.13.2) entdecken zusammengehörende Muster und geben dies in einer Grafik zum Beispiel weiter zur weiteren Interpretation.

2.12 Domänenklassen

Neuronale Netzwerke können sehr vielseitig eingesetzt werden. Grundsätzlich lässt sich jedes Problem, welches als Funktion repräsentiert werden kann, durch ein Neuronales Netzwerk approximieren.

In dieser Arbeit werden sieben Hauptdomänen erklärt und beschrieben, welche von Heaton [3] definiert wurden. Im Speziellen wird auf die Neuronalen Netzwerke eingegangen, welche öfter zum Einsatz kommen und eingesetzt werden.

2.12.1 Clustering

Das Clustering Problem bezeichnet das Einordnen von Daten in Klassen oder Gruppierungen. Diese Gruppierungen können von einem Netzwerk selbst definiert werden oder manuell festgelegt werden. Im Falle einer Self-Organizing-Map werden die Gruppierungen selbst durch das System festgelegt.

2.12.2 Regression

Regression beschreibt den Fall, in welchem Daten generiert werden und das kontinuierlich. Ein Anwendungsfall ist das Finden einer zugrundeliegenden Funktion, bei der nur Resultate dieser Funktion vorliegen. Somit werden aus Daten weitere Daten erzeugt. So gibt es Abläufe in der Natur, welche approximiert werden, um sie für weitere Systeme möglicherweise zu verwenden. [2]

2.12.3 Klassifikation

Das Klassifikation-Problem ist in gewisser Weise ähnlich zu dem Regression-Problemen. Der Unterschied liegt im Ergebnis, welches produziert wird. Hier werden Daten dem Netzwerk übergeben und dieses muss vorhersagen, zu welcher Klasse sie gehören. Dies wird in einer überwachten Umgebung durchgeführt. Die Klassen für die Vorhersage sind vorab schon bekannt und können mit den Daten aus dem Outputlayer des Netzwerks verglichen werden und infolge Justierungen durchgeführt werden. [3]

Ergebnisse einer Klassifikation sagen aus, zu wie viel Prozent etwas auf den gegebenen Input zutrifft. Das gesamt Ergebnis ergibt immer 100 Prozent. Das Ergebnis bei einer Regression wird dabei nicht in Prozent angegeben, sondern stellt einen konkreten Wert dar.

2.12.4 Predict

Predict-Problemstellungen kommen im Kontext von Business, beziehungsweise von E-Business zur Anwendung vor. Hier muss anhand von meist zeitgesteuerten Ereignisse eine Vorhersage getroffen werden. Zum Beispiel an der Börse ändern sich täglich die Kurse relativ rasch, sodass es für Menschen praktisch nicht mehr möglich ist, diesen zu folgen. Im Falle der Börse sind zeitlich Kurse aus der Vergangenheit verfügbar. Diese können als Trainingsdaten für ein Netzwerk verwendet werden, um den nächsten Tag möglicherweise vorherzusagen. Es kann somit als eine Spezialisierung von Regression und Klassifikation angesehen werden, da Daten generiert werden diese aber mit einer Wahrscheinlichkeit.

2.12.5 Robotics

Auch bekannt unter dem Namen Robot-Learning. Dabei lernen Roboter eigenständig neue Techniken oder passen sich automatisch ihrer Umgebung an. Eines der Kernprobleme dabei ist, dass in Echtzeit etwas Dreidimensionales in einer höhere Dimension berechnet werden muss. Aus diesen Daten muss zur selben Zeit gelernt werden, aber auch Aktionen eingeleitet werden, wie das Steuern von Motoren um zum Beispiel nicht umzufallen.

2.12.6 Computer Vision

Computer Vision zielt darauf ab, einem Computer das Sehen und Verstehen von Bildern zu ermöglichen. Diese Technik findet im Jahr 2016 schon häufig Einsatz. So werden automatisiert Bilder analysiert, beschrieben sowie auch in Gruppen nach diversen Kategorien eingeordnet, wie zum Beispiel Gesichtsausdrücke. Solche Dienste werden auch kommerziell eingesetzt und auch angeboten. In autonom gesteuerten Fahrzeugen findet diese Technologie auch bereits Verwendung um Objekte zu erkennen und zu verstehen. So muss zum Beispiel ein Verkehrszeichen von einem Passanten unterschieden werden können.

2.12.7 Optimierung

Optimierung bezieht sich auf eines der Grundprobleme der Informationstechnologie. So werden immer bessere schnellere Algorithmen entwickelt, welche konkrete Probleme noch effizienter lösen können. Durch das Thema BigData entstand ein Performanz-Problem, sodass selbst sehr effiziente Algorithmen einige Problemstellungen nicht mehr in konstanter oder adäquater Zeit lösen können. Das 'Salesman' Problem gehört zu diesen Problemen. Durch Optimierung wird in konstanter Zeit eine Lösung ermittelt, welche nicht die beste Lösung repräsentiert. Diese Lösung liegt aber im Rahmen einer bestimmten definierten Toleranz und kann als Lösung verwendet werden. [3]

2.13 Neuronale Netzwerktypen

In den letzten Jahren haben sich diverse gut funktionierende Neuronale Netzwerktypen gebildet, beziehungsweise sind entwickelt und erforscht worden. Diese Netzwerktypen definieren Richtlinien oder Ansätze zu möglichen Netzwerken, welche aber nicht komplett übernommen werden müssen, sondern einen kreativen Spielraum ermöglichen.

2.13.1 FeedForward

FeedForward Netzwerke (FFN) waren bis vor einigen Jahren noch der Stand der Forschung. Auf ihnen basieren einige andere Typen von Netzwerken, die bekanntesten werden in dieser Arbeit noch behandelt. Ein FFN basiert auf den Grundlagen eines Neurons (Neuron 2.5), sowie dem Ausbauen dieses zu Ebenen mit mehreren Neuronen (Layer 2.6). So ein Netzwerk besitzt einen Inputlayer, einen Hiddenlayer sowie einen Outputlayer. Sobald das Netzwerk mehrere Hiddenlayer aufweist, wird es als Deep FeedForward Netzwerk (2.13.5) bezeichnet. Das FFN weist dabei eine Charakteristik auf, in der der

Datenfluss eindeutig definiert ist. Der Datenfluss beginnt beim Inputlayer und endet beim Outputlayer, ohne dass ein Datenrückfluss zum Beispiel vom Hiddenlayer in den vorhergehenden Hiddelayer vorhanden ist. Dies würde eine Rekursion oder einem Kurzzeitgedächtnis entsprechen. Die einzelnen Ebenen müssen dabei aber nicht voll verbunden sein, die Vernetzung kann selbst bestimmt werden.

2.13.2 Self-Organizing Map

Self-Organizing Map (SOM) findet vor allem im Bereich der Classification (2.12.3) Verwendung und wurde von Kohonen (1988) erfunden. Es ist nicht erforderlich einer SOM die Information zu geben, in wie viele Gruppen oder Klassen die Daten unterteilt werden sollen. Dadurch gehört es zu den Systemen, welche unsupervised trainiert werden. Außerdem besitzen sie die Möglichkeit, sich auch nach der Trainingsphase auf sich ändernde Eingangsdaten anzupassen. Kohonen entwarf die SOM mit zwei Ebenen, einem Inputlayer und einem Outputlayer ohne Hiddenlayer. Der Inputlayer propagiert Muster an den Outputlayer, wo der Dateneingang gewichtet wird. Im Outputlayer gewinnt das Neuron, welches den geringsten Abstand zu den Eingangsdaten hat. Dies geschieht durch das Berechnen der euklidischen Distanz. Diese Art von Netzwerk kommt ohne Bias Neuron (siehe 2.5) aus und es kommen ausschließlich Lineare Aktivierungsfunktionen zur Verwendung.

2.13.3 Hopfield Neuronal Network

Ein Hopfield Neuronal Network (HNN) ist ein einfaches Netzwerk, welches aus einem Layer besteht. In diesem Layer sind alle Neuronen mit jedem anderen Neuron verbunden. Dieses Muster wurde von Hopfield (1982) erfunden. Im Gegensatz zu anderen Netzwerken können Hopfield Netzwerke in einer Matrix abgebildet werden, in welcher die Gewichtung zu den einzelnen Neuronen abgebildet werden. Die Neuronen selbst nehmen dabei den Zustand 1 für wahr und -1 für falsch an. Das Problem bei diesem Typ ist, dass jedes Neuron auf dem Status des anderen aufbaut. Dies stellt ein Problem für die Reihenfolge der Berechnung dar, was zu einem nicht stabilen Zustand führt. Durch das Hinzugeben einer Energiefunktion kann festgestellt werden, in welchem Zustand sich das Netzwerk befindet.

2.13.4 Boltzmann Machine

Im Jahre 1985 stellten Hinton & Sejnowski das erste Mal eine Boltzmann Maschine vor. Es stellt ein Zwei-Ebenensystem dar, mit einem Inputlayer und einem Outputlayer, wo jeder Knoten mit jedem verbunden ist, außer mit sich selbst. Das voll vernetzte System unterscheidet eine Boltzmann Maschine von einer eingeschränkten Boltzmann Maschine (RBM), welche eine Grundlage für tiefes Lernen und tiefe Neuronale Netzwerke darstellt. In

einer RBM sind alle sichtbaren Neuronen mit allen Neuronen im Outputlayer verbunden. Die Verbindungen zwischen den Neuronen in dem selben Layer entfallen. Der alte uneingeschränkte Type der Boltzmann Maschinen eignet sich gut für Optimierungsprobleme sowie für Mustererkennungen.

2.13.5 Deep FeedForward

Deep FeedForward Netzwerke unterscheiden sich von den normalen FeedForward Netzwerken, in dem dass sie mehrere Hiddenlayers beinhalten anstatt nur einem.

2.13.6 NEAT

NeuroEvolution of Augmenting Topologies (NEAT) Netzwerke sind relativ jung, wobei NEAT für einen Algorithmus steht der Neuronale Netzwerke entwickelt. Er wurde von Stanley und Miikkulainen (2002) entwickelt. Dieser Type verwendet genetische Algorithmen, um die Struktur und die Gewichtungen im Netzwerk zu optimieren. Die Input- und Outputlayer sind identisch einem FeedForward Netzwerk. Dafür fehlt diesem Type eine innere Struktur. Die Verbindungen sind lose, nicht klar definiert und können während dem Entwickeln entfernt werden, aber auch wieder hinzugefügt werden.

Compositional pattern-producing network (CPPN) ist ein Netzwerk das andere Strukturen entwickelt und basiert dabei auf der Theorie von NEAT. Dies können Bilder aber auch andere Netzwerke sein, wobei meist Bilder generiert und weiter entwickelt werden. CPPN können im Gegensatz zu NEAT Netzwerken mit verschiedenen Aktivierungsfunktionen verwendet werden. Ein erzeugtes finalisiertes Netzwerke resultiert aber immer in einem regulären NEAT Netzwerk.

HyperNEAT (*VL weglassen*) ist eines der bekanntesten CPPN Netzwerke, welches keine Bilder produziert, sondern neue Netzwerke erstellt. Mit der Fähigkeit andere Netzwerke zu kreieren, welche für ihre Aufgabe gute Ergebnisse liefern, ermöglicht es schneller Netzwerke zu kreieren und sich auf ändernde Probleme schneller anzupassen.

2.13.7 Convolutional Neural Network

Convolutional Neural Network werden selbst nicht als komplettes eigenes Netzwerk verwendet, sondern in FeedForward Netzwerken. Im Speziellen, wenn es sich um Bilderkennung geht. Dabei werden entweder zwei Ebenen nicht voll vernetzt sondern nur teilweise und somit Gewichtungen eingespart. Im zweiten Fall werden die Gewichtungen geteilt, sodass immer in

die selbe Richtung verlaufende Verbindungen die selbe Gewichtung aufweisen. Dies ermöglicht es komplexe Strukturen zu speichern und trotzdem die Speicherauslastung niedrig zu halten und die Effektivität aufrecht zu halten.

2.13.8 Recurrent Network

Sind Netzwerke die nicht nur einen Kontrollfluss haben, sondern auch Rekursionen beinhalten. Diese Rekursionen können jedes andere Neuron ansprechen, ausgenommen der Neuronen im Inputlayer. Ein Problem durch Rekursionen sind endlos Schleifen, welche behandelt werden müssen. So können Kontext Neuronen verwendet werden, aber auch eine definierte Anzahl an Iterationen durchlaufen werden, wo die Rekursion nicht mehr fortgeführt wird. Eine weitere Option ist so lange zu warten, bis sich die Ausgabe des Neurons stabilisiert hat und sich nicht mehr ändert. Das Kontext Neuron nimmt dabei die Stelle eines kurzen Speichers ein, wo ein Zustand für die nächste Iteration zwischengespeichert wird. Die Informationen, die in einem solchen Neuron gespeichert werden, werden bei diesem Speichervorgang nicht gewichtet, sondern erst, wenn diese Information an das Netzwerk zurückgegeben werden. Diese Rekursionen werden vor allem in Fällen verwendet, wenn es um zeitliche Abläufe und Änderungen geht, wie zum Beispiel mit der Temperatur für den nächsten Tag, wo man Jahre an Daten zur Verfügung hat.

Elman Network wurde im Jahre 1990 vorgestellt und verwenden Rekursionen mit Kontext Neuronen. Dabei existieren zwei Hiddenlayers mit einem Layer für normale Neuronen und einem mit Kontext Neuronen. Die Kontext Neuronen sind dabei voll verbunden mit dem Hiddenlayer und dieser gibt die Informationen ungewichtet an die Kontext Neuronen weiter. In diesem System existieren so viele Kontext Neuronen wie Neuronen im Hiddenlayer, sodass jedes Neuron dort ein Kontext Neuron mit dem neuen Status befüllt.

Jordan Network wurde 1993 der Öffentlichkeit präsentiert und sind den Elman Netzwerken sehr ähnlich. Es werden wieder Kontext Neuronen für das Zwischenspeichern verwendet, nur wird dieser Zustand durch den Outputlayer definiert. So wird der Ausgang gespeichert und in der nächsten Iteration wieder verwendet. Das Kontext Neuron ist dabei nur mit dem Outputlayer wieder verbunden und nicht mit einem Hiddenlayer.

2.14 Domänen und Typen Matrix

Wie in der Abbildung 2.4 erkennbar ist, existiert kein Netzwerk Grundtyp, der für alle Problem domänen geeignet ist. Dies führt zu der Schlussfolgerung, dass je nach Aufgabe und Ziel ein entsprechendes Grundgerüst gewählt werden muss. Auf Basis dieses Grundgerüsts können uneingeschränkt

	Clust	Regis	Classif	Predict	Robot	Vision	Optim
Self-Organizing Map	✓✓✓				✓	✓	
Feedforward		✓✓✓	✓✓✓	✓✓	✓✓	✓✓	
Hopfield			✓			✓	✓
Boltzmann Machine			✓				✓✓
Deep Belief Network			✓✓✓		✓✓	✓✓	
Deep Feedforward		✓✓✓	✓✓✓	✓✓	✓✓✓	✓✓	
NEAT		✓✓	✓✓		✓✓		
CPPN					✓✓✓	✓✓	
HyperNEAT		✓✓	✓✓		✓✓✓	✓✓	
Convolutional Network		✓	✓✓✓		✓✓✓	✓✓✓	
Elman Network		✓✓	✓✓	✓✓✓			
Jordan Network		✓✓	✓✓	✓✓	✓✓		
Recurrent Network		✓✓	✓✓	✓✓✓	✓✓	✓	

Abbildung 2.4: Domänen zu Typen Matrix [3]

weitere Eigenheiten aus anderen Netzwerken eingebaut werden. In der Praxis findet man selten ein Netzwerk von einem Typ. Meistens sind es einige mehrere Netzwerke unterschiedlicher Typen, die hintereinander und parallel geschaltet sind und so ein ganzes System darstellen. Dabei übernimmt jedes Teilnetzwerk eine kleine Aufgabe des gesamten und zwar eine für die es entwickelt wurde. Aktuelle Netzwerke wie das Inception v3 Netzwerk von Google Research benötigt zwei Wochen mit acht Grafikkarten zum Trainieren. Ab diesem Zeitpunkt ist es im Stande akkurate Resultate zu liefern. Dieses Netzwerk ist sehr komplex und besteht nicht nur aus 3 Ebenen, was zur Schlussfolgerung führt, dass umso tiefer das Netzwerk ist, umso aufwändiger ist es zu Trainieren.

2.15 Optimierung

Optimierungen beeinflussen das Lernverhalten und das Speicherverhalten eines Netzwerkes.

Lernrate skaliert die Lerngeschwindigkeit. Wie im Punkt Backpropagation 2.9 beschrieben.

Momentum gehört auch zur Optimierung im Algorithmus zur Backpropagation. Dieser bestimmt wie stark frühere Gewichtsaktualisierungen berücksichtigt werden sollen.

DropOut gehört zur Kategorie der Regulatoren. Hinten (2012) beschreibt DropOuts als eine effektive Art, um Overfitting (siehe 2.10) zu vermeiden. DropOut kann als System integriert werden, aber auch als eigener Layer

in einem Netzwerk. In einem Dropout Layer werden immer Neuronen deaktiviert, inklusive ihrer Verbindungen zu dem nächsten Layer. Dies hat zur Folge, dass nur ein geringerer Teil an Informationen aus dem vorhergehenden Layer in den Nächsten übergeht. Durch diesen Prozess, des künstlichen Geringhaltens von Informationen während dem Training führt dazu, dass das Netzwerk trotz dieser Einschränkung versucht ein gutes Ergebnis zu erzielen. Während der Test- und Produktivphase werden diese Dropout Layer aber meist deaktiviert, da das volle Potenzial des Netzwerks verwendet werden möchte.

L1 und L2 Regularisierung sind auch Techniken, die zur Verhinderung von Overfitting beitragen. Im Gegensatz zu der Dropout Strategie sind diese zwei Regulationstechniken Teil der Backpropagation oder Teil einer Funktion. Beide Techniken arbeiten mit Strafen, welche verteilt werden und so die Gewichtungen in ein Muster zwingen. Im Falle von L1 ähnelt dieses Muster einer Gaussian Glockenkurve und bei L2 einer Laplace Kurve. Durch das Bestrafen der Gewichtungen im Netzwerk werden diese Werte gering gehalten, sodass sie nicht ausarten. Wenn ein Gewicht Richtung 0 geht, führt dies unweigerlich zu einem indirekten Ausschluss aus dem Netzwerk. Das Netzwerk wird spärlicher und leichtgewichtiger, was aber wiederum als Resultat hat, dass ein Rauschen in den Daten möglicherweise erkannt wird und ignoriert wird.

$$E := \frac{\lambda}{n} \sum_w |w| \quad (2.2)$$

Die Funktion 2.2 bildet die Berechnung der Strafe in der Backpropagation ab. Das λ definiert wie stark die Regulierung den Error-Wert des Netzwerkes beeinflussen soll. Ein Wert von 0 führt dazu, dass die Regulierung keinen Einfluss besitzt. Im einem normalen Fall ist dieser Wert kleiner als 0.1(10%). Der Divisor n wird durch die Anzahl an Elementen im Trainingssatz und der Anzahl an Neuronen im Outputlayer bestimmt. Zum Beispiel bei 100 Elementen im Trainingssatz und 3 Neuronen im Outputlayer würde der Divisor den Wert 300 einnehmen. Dies ist erforderlich da diese Funktion bei jeder Evaluierung der Trainingsdaten berechnet wird.

GPU - GPGPU ist die Bezeichnung für die Verwendung des Grafikprozessors über seine ursprüngliche Auslegung darüber hinaus. In der aktuellen Zeit ist es nicht mehr möglich eine Geschwindigkeitssteigerung zu erreichen, in dem die Taktrate des Prozessors erhöht wird. Deshalb wird mehr parallelisiert, da die Recheneinheiten kleiner werden und so mehrere auf die selbe Fläche platz finden. Eine Grafikkarte besitzt die Eigenschaft, gleichförmige Operation in einem Schritt auf sehr viele Objekte gleichzeitig auszuführen. So werden viele Pixel in einmal eingefärbt oder eine Multiplikation großer

Matrizen. Der Geschwindigkeitsvorteil kommt dabei durch den hohen Grad an Parallelität, da die Grafikkarte hauptsächlich für solche Operationen ausgelegt worden ist.

Batch Learning gehört nicht direkt in die Kategorie der Optimierung, bietet trotzdem wie einen Performanzvorteil. Durch Batch Learning wird immer ein Paket in das System eingeführt. Dieses Paket wird je nach Implementierung parallel verarbeitet oder sequenziell. Der Unterschied zu 'Online Learning' ist nun, dass nicht nach jedem Durchlauf die Gewichtungen und das System nachjustiert werden, sondern dass zu Erst das Paket verarbeitet wird und das System einmal angepasst wird. Wenn also ein Paket mit einer Größe von 64 in das System eingeführt wird, führt dies einmal zu einer Anpassung des Graphen, in dem die Gradienten zusammen gerechnet werden und einmal auf den Graphen adaptiert werden. [3]

Kapitel 3

TensorFlow

TensorFlow repräsentiert eine Bibliothek für Machine Intelligence. Historisch gesehen entstand TensorFlow in der Google Brain Abteilung. Das Projekt wird als Open Source Projekt weiterentwickelt, wobei das Projekt von Google weiterhin gepflegt wird. Das Offenlegen des Projekts führt dazu, dass auch Personen außerhalb von Google die Möglichkeit bekommen, die Bibliothek zu verwenden sowie dazu etwas beitragen zu können.

Das Hauptkonzept in TensorFlow sind sogenannte Tensoren, welche einen Graphen durchlaufen. Der Graphen selbst stellt damit einen Datenflussgraphen dar, welcher Knoten beinhaltet. Diese Knoten bilden numerische Operationen ab. Der Informationsaustausch zwischen den Knoten geschieht mit multidimensionalen Arrays, den so genannten Tensoren. TensorFlow bietet wie andere Bibliotheken die Möglichkeit die Berechnungen auf eine Grafikkarte auszulagern. Zusätzlich sind weite Routinen eingebaut, damit das Trainieren über mehrere Grafikkarten verteilt werden kann sowie auf weitere Computer.

TensorFlow steht für mehrere Programmiersprachen zur Verfügung, welche offiziell unterstützt werden, wobei es noch mehr durch die Open Source Gemeinschaft unterstützte Sprachen gibt. Den Hauptbereich stellt die Python API dar, welche auch die vollständigste Implementierung darstellt. Der Kern von TensorFlow ist mit C++ und Python implementiert und wurde sehr stark optimiert, um eine sehr gute Performanz zu erzielen. Die Python API wird im Umfeld von TensorFlow dazu verwendet, um einen Graphen zu erstellen, zu trainieren und zu testen. Durch die Verwendung von Python besteht die Möglichkeit sehr schnell Änderungen am Graphen durchzuführen und nicht erst ganze Applikationsstrukturen zu übersetzen, damit ein Ergebnis der Änderung ersichtlich wird. Dieser Graphen wird nach seiner Trainingsphase exportiert und beinhaltet alle Knoten sowie die dazugehörigen Gewichtungen. Die C++ API sowie die Java API und GO API zielen

```

1 import tensorflow as tf
2
3 b = tf.Variable(tf.zeros([100]))
4 # 100-d Vektor, initialisiert mit 0
5 W = tf.Variable(tf.random_uniform([784,100],-1,1))
6 # 784x100 Matrix w/rnd vals
7 x = tf.placeholder(name="x")
8 # Platzhalter für Eingangsdaten
9 relu = tf.nn.relu(tf.matmul(W, x) + b)
10 # Relu(Wx+b) Aktivierungsfunktion mit impliziter Addition
11 C = [...]
12 # Kostenfunktion und noch weitere Knoten
13 s = tf.Session()
14 for step in xrange(0, 10):
15     input = ...construct 100-D input array ...
16     # Erstellen eines 100-d Vektor mit den Eingangsdaten
17     result = s.run(C, feed_dict={x: input})
18     # Graphen mit den Eingangsdaten ausführen
19     print step, result
20     # Ausgabe des Berechneten Resultats

```

Abbildung 3.1: TensorFlow Codefragment zur Definition eines Teils des Graphen




Abbildung 3.2: Der resultierenden Teilgraph aus dem Codefragment aus Abbildung 3.1 nach dem Beispiel in [1]

auf eine sehr effiziente Ausführung ab. Durch die Verwendung des trainierten Graphen kann dieser auch auf mobilen Plattformen eingesetzt werden.

3.0.1 Graphs/Dataflowgraph

Ein TensorFlow Graph kann wie in Abbildung 3.1 beschrieben werden. Dieser wurde zum Beispiel mit der Python API erstellt. Im Gesamten mit den Knoten und den Verbindungen ergibt sich ein Datenfluss, diese beinhaltet alle erforderlichen Komponenten auch für das persistieren und aktualisieren der Daten. Dies sind Erweiterungen für den Hauptgraphen und beinhalten auch Logik für Schleifenverwaltungen. Ein Knoten in einem Graphen besitzt 0 bis n Ein und Ausgänge und besitzt eine Kernfunktion. Zu den Datenhauptfluss mit den Tensoren gibt es zusätzlich spezielle Verbindungen,

welche "control dependencies" genannt werden. Anhand dieser Verbindungen werden keine Daten im Sinne der Tensoren übertragen, sondern werden benutzt um Abhängigkeiten zu definieren, um zum Beispiel eine Ausführung in einem anderen Knoten vor einem anderen zu definieren. So muss der Quellknoten mit der Ausführung abgeschlossen haben bevor der darauf wartende mit der Ausführung beginnt. [1]

3.0.2 Operation

Die Operation stellt in jedem Knoten den Kern dar, wie zum Beispiel eine Matrix Multiplikation oder eine Addition. In TensorFlow selbst gibt es einen Unterschied zwischen Operation und Kernel. Operationen besitzen Attribute, welche spätestens zum Zeitpunkt der Grapherstellung bekannt sein müssen. Ein solches Attribut wäre zum Beispiel, *um eine Operation Polymorph für Datentypen zu ermöglichen*. Der Kernel selbst ist die Implementierung der Operation selbst. Dieser kann auf verschiedenen Geräten ausgeführt werden wie CPU oder GPU. Die Operationen und die dazugehörigen Kernel werden über einen Registrierungsmechanismus zur Verfügung gestellt. Diese Sammlung an Operationen kann auch Erweitert werden. [1]

3.0.3 Sessions

Die Session repräsentiert die Laufzeit für einen Graphen. Dieser Session wird ein Graphen übergeben, welcher erst initialisiert werden muss. Ohne die Initialisierung ist der Knoten und Verbindungen würde die weitere Ausführung mit diesem nichts produzieren, da alle Werte 0 sind. Diese stellt eine weitere Funktion zur Verfügung *Run*. Der Run-Funktion wird eine Liste Endknoten übergeben welche berechnet werden sollen und die zu dem initialisierten Graphen gehören. Die Platzhalter Tensoren werden mit Daten verknüpft und so in den Graphen gereicht. In den Meisten Fällen wird ein Graphen einmal erstellt und mehrfach ausgeführt. [1]

3.0.4 Tensor

In TensorFlow ist ein Tensor ein typisiertes multidimensionales Array. Die verwendbaren Typen reichen von Datentypen mit Vorzeichen und ohne sowie bis hin zu Doubles und Zeichenketten. [1]

3.0.5 Hyperparameter

Hyperparameter werden im Umfeld von maschinellem Lernen verwendet, um Variationen an Kombinationen zu testen. Dabei werden verschiedenste Parameter getestet, wie verschiedene Aktivierungsfunktionen oder Optimierungsalgorithmen, aber auch die Anzahl an Ebenen und Breiten dieser. Im Gesamten führt dies meist zu sehr vielen Permutationen, welche ausgetestet

werden müssen und somit voll trainiert werden. Da die Zeit welche dafür benötigt werden würde, nicht in einer Relation dazu steht, werden solche BruteForce Tests nur mehr selten durchgeführt. Für diesen Fall existieren eigene Techniken, welche sich nur um das Optimieren der Hyperparameter kümmern. [2]

3.1 Bibliotheksinhalt

3.1.1 Datentypen

TensorFlow besitzt eine große Anzahl an Datentypen die verwendet werden können. Dies reicht von Grunddatentypen wie 'Boolean' und 'String' bis hin zu verschiedene Integer Datentypen. Diese stehen in verschiedene Wertebereichen zur Verfügung. So gibt es Gleitkommazahlen mit unterschiedlicher Genauigkeit, wie 16-bit was für halbe Genauigkeit steht aber auch bis zu 64-bit Genauigkeit reicht, was einer doppelten Genauigkeit entspricht. Der Grund für diese verschiedenen Anzahlen an Datentypen ist, dass diese zur Optimierung verwendet werden können. Ein trainiertes Netzwerk welches nie in den Wertebereich von 64-bit signierte Integers gekommen ist, wird diese möglicherweise nie benötigen. In diesem Fall können die Wertebereiche reduziert werden, auf zum Beispiel 32-bit signierte Integer und somit die Berechnungen hochperformanter ausgeführt werden. [5]

3.1.2 Operationen

Konstanten und Zufallswerte

Konstanten stehen in TensorFlow vordefiniert zur Verwendung. Diese stellen initialisierte Tensoren für den ersten Trainingsdurchlauf zur Verfügung.

- *tf.zeros* erstellt einen Tensor mit angegebenen Dimension bestehend aus 0 und von einem Datentypen.
- *tf.zeros_like* gibt einen Tensor zurück, welcher die selbe Dimensionen wie der gegeben besitzt. Alle Werte in diesem Tensor sind aber auf 0 gesetzt. In diesem Zuge kann der Datentyp mit angepasst werden, wenn nur die Dimensionen übernommen werden sollen.
- *tf.ones* agiert genau wie der Tensor *tf.zeros* mit dem unterschied dass alles mit 1 gefüllt ist.
- *tf.ones_like* repräsentiert das selbe wie *tf.zeros_like* nur mit 1.
- *tf.fill* wird zu der Dimension noch ein Skalar mit gegeben, für die Werte die ausgefüllt werden sollen.
- *tf.constant* liefert einen Tensor mit selbst definierbaren Werten. Diese Werte können eine Liste sein sowohl als auch ein einzelner Wert

welcher überall eingefügt werden soll.

Sequenzen können verwendet werden um einen Wertebereich in eine bestimmte Anzahl an Werte zu zerteilen und diese als Tensor in das System einfließen zu lassen.

- *tf.lin_space* generiert einen eindimensionalen Tensor vom Datentypen 32 oder 64-bit Gleitkommazahlen, mit einer bestimmten Folge. Diese beginnt mit dem Startwert und endet mit dem Endwert. Die Werte dazwischen werden gleichmäßig verteilt erstellt.
- *tf.range* erstellt wie *tf.lin_space* einen eindimensionalen Tensor mit Skalarwerten. Die Folge beginnt mit einem Startwert und erweitert sich um ein Delta bis zum Endwert, welcher nicht Teil der Folge ist.

Zufallswerte werden im Bereich von maschinellen Lernens sehr häufig benötigt. So werden meist der Startzustand mithilfe von Zufallszahlen hergestellt.

- *tf.random_normal* liefert einen Tensor mit Zufallswerten anhand einer Normalverteilung (Gaussian). Die Dimension des Ergebnistensors muss spezifiziert werden, der Meridian, Standardabweichung sowie der resultierende Datentyp können angegeben werden.
- *tf.truncated_normal* verhält sich gleich zu *tf.random_normal* mit dem Unterschied, dass Werte die größer sind als 2-mal die Standardabweichung, ignoriert werden und ein neuer Wert ausgewählt wird.
- *tf.random_uniform* generiert einen Tensor in welchem Werte gleich Wahrscheinlich vorkommen. Die Werte werden aus dem spezifizierten Wertebereich genommen, wobei diese exklusive der oberen Grenze ist, wie zum Beispiel '[0,1)'.¹
- *tf.random_shuffle* erstellt selber keine neuen Werte sondern, mischt einen Tensor anhand seiner ersten Dimension durch.
- *tf.random_crop* liefert einen zufälligen Teil eines Tensors mit der selben Anzahl an Dimensionen und aber mit der spezifizierten Größe.

Einige dieser Funktionen benötigen sogenannte Seed-Werte, welche den Startwert der Zufallszahlen zerstreuen sollen sowie die Folge selbst. Im Falle von TensorFlow beruht dies auf zwei Werten, einer wird für den Graphen spezifiziert, der zweite wird für die Operation selbst spezifiziert. Der Wert für den Graphen kann mit *tf.set_random_seed* gesetzt werden. Für weitere Informationen steht die online Dokumentation zur Verfügung.¹

¹Online Dokumentation: Constants, Sequences, and Random Values https://www.tensorflow.org/api_guides/python/constant_op

Variables

Variablen geben bei jedem Durchlauf einen Tensor ab. Dieser Wert ändert sich nicht, außer ihm wird ein neuer Wert zugewiesen.

Transformationen

Casting bietet die Möglichkeit wie in anderen Programmiersprachen Typen zu konvertieren. Diese Operation muss in den Graphen eingepflegt werden, da keine impliziten Konvertierungen durchgeführt werden. Es kann jeder Tensor konvertiert werden, sowie eine Zeichenfolge in eine Zahl. Bei diesem Vorgang kann ein Fehler entstehen, welcher in *TypeError* resultiert.

Shapes und Shaping liefert die Gestalt eines Tensors, bietet aber auch die Möglichkeit diese zu ändern.

- *tf.shape* liefert eine genaue Aufschlüsselung des Tensors mit der Dimension und der Tiefe.
- *tf.size* repräsentiert die Anzahl an Elementen in einem Tensor. Diese Anzahl ergibt sich aus den konkreten Werten.
- *tf.rank* verhält sich ähnlich zu *tf.size* mit dem Unterschied, dass die Anzahl der Felder Vertiefung gezählt wird.
- *reshape* wird verwendet um Tensoren in eine neue Struktur zu bringen. Dabei kann für das Einebnen der Dimensionen eine Kurzschreibweise verwendet werden mit -1 als Zielausführung der Gestalt.
- *tf.squeeze* entfernt ganze Dimensionen aus dem gegebenen Tensor. Ohne Achsen Angabe werden alle Dimensionen mit der Größe 1 entfernt oder es werden die spezifizierten Dimensionen herausgenommen.
- *tf.expand_dims* gliedert wieder um Dimensionen in einen Tensor ein. Im Standard an der Indexstelle 0, außer es wurde spezifiziert.

Slicing und Joining wie in diversen Programmiersprachen unterstützt auch TensorFlow das Teilen und Zusammenfügen von Daten und aber hier im Speziellen mit Tensoren. Diese Operationen reichen von einfachen Slicing Operationen über Transponieren bis hin zu dem Verketteten von Tensoren, dabei kann definiert werden anhand welcher Achse der Dimensionen die Operation ausgeführt werden soll.

Weitere Informationen befinden sich in der online Dokumentation.²

²Online Dokumentation: Tensor Transformations https://www.tensorflow.org/api_guides/python/array_ops

Mathematik

Arithmetische Operationen stellen die mathematischen Grundoperationen dar. Diese können teilweise in Kurzschreibweisen verwendet werden, wie zum Beispiel die Addition. Diese kann entweder als explizite Operation `tf.add(x, y)` verwendet werden aber auch Implizit bei der Addition `+` von einem Tensor mit einem Bias-Tensor.

Basis Funktionen ergänzen die arithmetischen Operationen um Standardfunktionen. Zu diesen Funktionen zählen die Berechnung der Absolutwerten in einem Tensor sowie eine Exponentialfunktion.

Matrizen Funktionen werden am häufigsten benötigt, da Tensoren im Grunde Matrizen sind und somit diese geändert werden können.

- `tf.matmul` führt eine Matrizenmultiplikation aus. Diese Operation findet meist in voll Vernetzten Neuronen Verwendung, wenn der übergebene Tensor mit der Gewichtung multipliziert wird.
- `tf.eye` erzeugt eine Identitätsmatrix, in welcher alle Werte an der Diagonale 1 sind und alle anderen 0.

Zu diesen Funktionen existieren noch weitere die zur Lösung von Gleichungen verwendet werden können. Diese Gleichungen müssen in Matrizen-schreibweise im Tensor abgebildet sein.

Komplexe Zahlen können verwendet werden und Operationen mit ihnen in de Graphen eingepflegt werden.

Reduzierungsoperationen kommen meist dann zum Einsatz, wenn der Unterschied zwischen dem Ergebnis und dem erwarteten Ergebnis festgestellt werden soll.

- `tf.reduce_sum` berechnet die Summe aller Werte in einem Tensor.
- `tf.reduce_mean` berechnet die Summe aller Werte an der Diagonale eines Tensors.
- `tf.reduce_max` reduziert einen Tensor auf die maximal Werte in der letzten Dimension und reduziert dabei den Rang um eins.

Zu diesen gibt es noch weiter, welche in diversen Fällen benötigt werden wenn zum Beispiel Wahrheitswerten reduziert werden sollen.

Die Anzahl an mathematischen Funktionen ist um einiges sehr viel Größer als die hier erwähnten. Diese hier repräsentieren lediglich die meist verwendeten Operationen. Für weiter Informationen steht die online Dokumentation zur Verfügung.³

³Online Dokumentation: Math https://www.tensorflow.org/api_guides/python/math_

Flusskontrolle

Flusskontrolle sind Operationen die den Ablauf in dem Graphen beeinflussen. Dies können Bedingungen sein, wie im Sinne von *if (Bedingung)... else* aber auch *switch (Term) case '0': ...; break;* Bedingungen sein. In beiden Fällen müssen die Auszuführenden Verzweigungen als Funktionen vorliegen. Zusätzlich gibt es noch eine *While* und eine *For* Schleife. Zu beachten ist, dass diese Operationen und weiter den Fluss durch den Graphen stark beeinträchtigen können.

Logik Operatoren können verwendet werden um Vergleiche zwischen Tensoren durchzuführen. Diese werden aber als Logik Operationen ausgeführt und liefern immer Wahrheitswerte, wie eine Logische Und-Verknüpfung auf Binärebene.

Vergleichsoperatoren neben den Logischen Operatoren stehen weitere Vergleichsoperatoren zur Verfügung. Hierzu zählen *tf.equal* sowie die verneinte Variante, *tf.less* und *tf.greater* mit jeweils einer gleich Version. Diese Operatoren geben wiederum einen Tensor mit Wahrheitswert aus.

Debugging Operationen ermöglichen es in den Graphen Kontrollstrukturen einzubauen, welchen auf diverse Bedingungen reagieren. So kann überprüft werden ob ein Tensor Werte mit undefinierten Zustand beinhaltet. Die Funktion *tf.Print* ermöglicht es Tensoren auszugeben wenn diese Funktion im Graphen evaluiert wird. Aktuell sind die Möglichkeiten eine Graphen zu debuggen relative eingeschränkt, da der Graphen ist grundsätzlich einsehbar aber schwer zu verstehen in seiner rohen Darstellung.⁴

Images

Encodieren und Decodieren von Bilddateien wird TensorFlow direkt unterstützt. Dabei können Bildern von den Datentypen Gif, Jpeg und PNG gelesen werden, sowie das erstellen von Bildern in diese Datentypen, ausgenommen Gif. In allen Fällen wird das Bild als Zeichenkette mit Pfad angegeben.

Größenänderung von Bildern sind erforderlich, da Bilder die eingelesen werden zu groß sind und somit in die Struktur des Graphen nicht eingelesen werden können. Für die Größenänderung stehen mehrere Implementierungen zur Verfügung mit unterschiedlichen Algorithmen und vorgehen im Hintergrund.

ops

⁴Online Dokumentation: Control Flow https://www.tensorflow.org/api_guides/python/control_flow_ops

Beschneiden wird dann benötigt wenn aus einem Bild ein Teil herausgenommen werden soll. Zum herausnehmen stehen wiederum mehrere Operationen zur Verfügung, welche mit umschließende Boxen arbeiten oder wie viel Prozent von der Mitte des Bildes aus genommen werden soll.

Flippen, Rotieren und Transponieren ermöglicht es Bilder zu Verändern, so dass es für einen Menschen mehr oder weniger immer noch die selbe Bedeutung hat aber nicht mehr für einen Computer. Für diesen stellt ein Rotiertes oder Gespiegeltes Bild ein neues Bild dar. Diese Technik wird beim Trainieren von Bilderkennungen eingesetzt um zum Beispiel aus geringen Datenmengen die zum Trainieren verfügbar sind, mehrere zu generieren.

Zusätzlich gibt es noch die Möglichkeit die Farbkanäle des Bildes zu ändern sowie das Bild nachzujustieren.⁵

Input und Readers

Platzhalter werden benötigt um einen Graphen zu erstellen. Ohne Platzhalter wäre es nicht möglich Daten in den Graphen zu bekommen. Diese müssen zur Ausführungszeit durch richtige Daten ersetzt werden, was mit Hilfe von einem Schlüssen-Wert-Paars erfolgt.

Readers ermöglichen direkt aus dem Dateisystem Daten zu laden. Dabei stehen spezifizierte Reader zur Verfügung welche die direkt Tensoren ausliefern sowie Zeile für Zeile oder ganze Dateiinhalte liefern.

Konvertierungsoperationen ermöglichen es Dateien die mit TensorFlow Readers gelesen wurden weiter zu verarbeiten, so kann eine CSV Datei decodiert verwendet werden.

Des Weiteren sind Protokoll Buffer sowie Queues implementiert die zum Vorverarbeiten von Daten sind.⁶

Neuronale Netzwerke

Neuronale Netzwerke sind eine Spezialisierung des Gebietes des maschinellen Lernens. So bietet TensorFlow eine breite Unterstützung beziehungsweise eine große Implementierungsvielfalt für diesen Typ an.

Aktivierungsfunktion repräsentieren den Ausgang eines Neurons dar, dabei existieren aus der Vergangenheit heraus einige Ansätze für diesen Bereich eines Neuronalen Netzwerkes.

⁵Online Dokumentation: Images https://www.tensorflow.org/api_guides/python/image

⁶Online Dokumentation: Input und Readers https://www.tensorflow.org/api_guides/python/io_ops




Abbildung 3.3: Sigmoide Aktivierungsfunktion

- *tf.sigmoid* ist eine der bekanntesten und ältesten diesen Typs. Diese Funktion hat im Punkt 0 einen Aktivierungswert von 0.5 und besitzt zwei Beschränkungen. Im negativen Zahlenbereich auf der X-Achse wird die Funktion mit 0 der Grenzwert definiert und im positiven Zahlenbereich auf der X-Achse wird diese mit dem Grenzwert von maximal 1 definiert. Ein negativer Wert führt somit zu einem geringen Aktivierungswert, welcher sich im Negativen an 0 annähert sowie im Positiven an 1. Im Diagramm 3.3 befindet sich dies Funktion mit ihren Grenzwerten.
- *tf.relu* ersetzt mittlerweile immer mehr die Sigmoid Version. Ein Grund dafür ist, dass die Berechnung mit Sigmoidfunktionen Ressourcen intensive ist. Die rektifiziert lineare Funktion ist sehr viel einfacher, denn Werte unter 0 werden als 0 weiter gegeben und Werte darüber linear. Somit resultiert ein Eingangswert von -0.1 in einer 0 und ein Wert von 0.5 in 0.5 . Wie im Diagramm 3.4 ersichtlich ist, führt dies bei einem negativen Wert dazu, dass eine Multiplikation mit der Gewichtung in der nächsten Ebene ebenfalls in einer 0 sich repräsentiert und somit in der Addition ignoriert wird.
- *tf.tanh* genannt als Hyperbolic Tangent gehört ebenfalls zu den grundlegenden Aktivierungsfunktionen. Der Unterschied zwischen dieser Funktion und der Sigmoiden Aktivierungsfunktion ist, dass der untere Grenzwert nicht bei 0 liegt sondern bei -1 . Im Diagramm 3.5 ist zu sehen, wo sich der Wendepunkt befindet, was im Falle des Hyperbolic Tangent in der Koordinate $x = 0, y = 0$ ist.

Zu diesen Aktivierungsfunktion stehen noch einige weiter zur Verfügung, die ausführlich getestet gehören. Im Grunde könnte jede Funktion verwendet werden, doch jede besitzt eine Eigenheit und beeinflusst so den gesamten Graphen.




Abbildung 3.4: rektifiziert lineare Aktivierungsfunktion




Abbildung 3.5: Hyperbolic Tangents Aktivierungsfunktion

Faltung Operationen werden bei Bilderkennungen unter anderem deshalb verwendet, da sie eine Operation auf einen Stapel an Daten gleichzeitig anwenden. So wird ein Fenster über ein Bild geschoben und auf jedes Bild wird in dem selben Fenster die Operation durchgeführt. Diese Operation generalisiert die darunterliegenden Daten, so als ob sie auf Etwas reagiert hätten. Dies entspricht dem als ob ein Auge auf etwas reagiert hätte. **TODO: Diagramm**

- *tf.nn.conv2d* steht für zweidimensionale Bilder zur Verfügung.
- *tf.nn.conv3d* ermöglicht es mit dreidimensionalen Objekten zu arbeiten.

Des Weiteren stehen noch weitere spezialisierte Versionen implementiert zur Verfügung.

Bündelung wird verwendet um Daten zu vereinfachen. Eine Faltungsoperation führt dazu, dass aus einem Bild viel erzeugt werden mit unterschied-

lichen Filtern. Eine Bündelung ermöglicht eine Vereinfachung der Bilder, sodass sie vereinfacht werden und dabei die Schlüsselinformationen aber dennoch erhalten bleiben. Diese Technik wurde zu früheren Zeiten eingesetzt, um Computerressourcen zu sparen, da diese nicht so leistungsfähig waren wie sie aktuell sind. TensorFlow bietet mehrere Umsetzungen, so kann der Maximalwert aus der Filtermatrix übernommen werden wie aber auch der Mittelwert.

Verluste beschreiben wie sehr ein Ergebnis von dem erwarteten Ergebnis entfernt ist. Diese Art der Verlust Feststellung wird bei Regression Probleme benötigt aber auch regulieren im generellen.

- *tf.nn.l2_loss* berechnet einen Wert, welcher den Inhalt des Tensors repräsentiert. Im Falle dieser Implementierung wird keine Wurzel des Quadrats berechnet, sondern es werden die Werte nur addiert und durch 2 dividiert.
- *tf.nn.log_poisson_loss* berechnet den Logarithmischen-Wahrscheinlichkeitsverlust zwischen einem Ergebnis und einem erwarteten Ergebnis. Diese Methode liefert im Normalfall nicht den exakten Verlust, was für Optimierungen nicht das Problem ist. Sollte trotzdem ein genaueren Wert berechnet werden zum Vergleichen von Verlusten, muss die aufwändige Stirling Approximation aktiviert werden.

Klassifizierungen repräsentieren einen großen Bereich des maschinellen Lernens. TensorFlow besitzt deshalb mehrere Hilfsfunktionen, welche das Arbeiten mit Klassifizierungen erleichtert.

- *tf.nn.softmax* bildet alle Ergebnisse auf einen prozentualen Bereich ab. So ergeben alle möglichen Ausgänge in Summe 100%, was soviel bedeutet das ein Ergebnis eine gewisse Wahrscheinlichkeit besitzt.
- *tf.nn.softmax_cross_entropy_with_logits* bietet einem die Möglichkeit auf nicht skalierte Daten ein Ergebnis zu Berechnen, welches eine *tf.nn.softmax* Berechnung liefern würde. Zusätzlich wird eine weitere so genannte 'cross entropy' Operation ausgeführt, wo das Ergebnis für Optimierungen benötigt wird. Die gesamte Methode berücksichtigt Spezialfälle im gesamten Prozess, welche schwer manuell ab zu berücksichtigen sind.

Zu diesen existieren noch weitere Implementierungen mit weiteren Eigenschaften, welche in diversen Situationen möglicherweise einen Vorteil bieten. Des Weiteren gibt es Implementierungen für Wiederkehrende Neuronale Netzwerke und weitere Dinge in diesem Themengebiet.⁷

⁷Online Dokumentation: Neural Network https://www.tensorflow.org/api_guides/python/nn

Running Graphs

Session stellt eine Hauptklasse des TensorFlow-Systems dar, mit der TensorFlow Engine im Hintergrund. In ihr werden alle Operationen ausgeführt und alle Tensoren evaluiert. Dieser Session wird der Graphen mitgegeben, in dem der Endpunkt des Graphen angegeben wird. Zur Ausführungszeit führt die Engine alle Operationen des Graphen durch und evaluiert die Tensoren in diesem. Die Engine führt dabei alles bis zu dem gegebenen Punkt aus, welcher als Ausgangspunkt übergeben wurde. Sollte der Graphen weiterführen, so wird dieser nicht mehr durchlaufen. Dies bietet eingeschränkte Möglichkeit, um das aufgebaute System zu testen. Eine Session wird mit *tf.Session* erstellt und stellt die Funktionalität zum Ausführen, sowie die Möglichkeit diese zu schließen zur Verfügung. Mit *tf.InteractiveSession* wird ebenfalls eine Session erstellt, diese wird aber zugleich als Basissession installiert. Dies bietet die Möglichkeit interaktiv in einer Kommandozeile Operationen auszuführen, ohne die Session explizit zu übertragen und anzusprechen. Die Tensoren und Operatoren bieten in diesen Fall die Option sich und den Graphen auszuführen, indem die Methoden *TensorVariable.eval* sowie *OperationsVariable.run* in diesen aufgerufen werden.

Zusätzlich kann eine bestehende Basissession geholt werden sowie auf Fehler reagiert werden.⁸

Training

Optimizers stellen einen weiteren Kernteil des Systems dar. TensorFlow stellt eine Menge an implementierten Optimierungsalgorithmen zur Verfügung. Diese Operationen trainieren den Graphen mit der gewählten Technik des gewählten Algorithmus. Diese Implementierungen versuchen die gegebenen Kosten eines Graphen zu minimieren. Bei der Verwendung von *minimize* führt die Operation zwei Schritte in einem aus. In diesem wird der Gradient berechnet und dieser wird direkt auf die Variablen adaptiert. Diese Schritte können in einzelne zerlegt werden wenn, sollte mit den berechneten Gradienten noch etwas zusätzlich durchgeführt werden. Die Berechnung wird dabei mit *opt.compute_gradients* ausgelöst, was eine Liste mit Paaren liefert. Diese Liste kann bearbeitet werden aber auch zu Testzwecken protokolliert werden. Die Gradienten werden im dritten Schritt mit *opt.apply_gradients* auf die Variablen angewendet. Jeder Optimierungsalgorithmus verfügt über Eigenheiten und spezielle Verhalten, welche berücksichtigt werden sollten bei der Auswahl des Optimierers.

Gradient Computation umfasst Methoden die das Verhalten des Graphen und der Optimierung beeinflussen. Diese Methoden ermöglichen es,

⁸Online Dokumentation: Running Graphs https://www.tensorflow.org/api_guides/python/client

Einfluss auf die Gradientenberechnung sowie auf dessen Evaluierung zunehmen. In diesem Sinne sind diese mit Vorsicht zu verwenden.

Verteilte Ausführung stellt eine der Stärken von TensorFlow dar, da diese Technologie schon im System implementiert ist und somit keine manuelle Verteilung der Aufgaben entwickelt werden muss. Dadurch besteht die Option die Berechnungen auf mehrere Geräte zu verteilen und so die zur Verfügung stehenden Ressourcen besser auszunützen.

Einige Komfortmethoden ermöglichen es einfacher eine Session zu erstellen und alle Variablen zu initialisieren, sowie im Anschluss zu trainieren, wobei eine Stopbedingung mit definiert werden kann. In diesem Zuge können Hooks einfach in das System integriert werden welche Aufgerufen werden. Im Weiteren kann Threading sowie der Verfall der Lernrate beeinflusst werden.⁹

TensorFlow beinhaltet noch sehr viele weitere Komponenten und Möglichkeiten. Dies würde aber den Rahmen und den ersten Einblick in die Materie des maschinellen Lernens und im speziellen von TensorFlow sprengen. Im Grunde kann mit diesem Grundlagen und ein Netzwerk erstellt werden und damit gearbeitet werden. Seit der Offenlegung kommen immer mehr Erweiterungen aus der Community dazu, was auch dazu führt, dass Teile die sehr oft benötigt werden und aus mehreren Komponenten bestehen als Modul oder Funktion zur Verfügung stehen. Im Zuge dessen besteht die Möglichkeit sich einen bestehen Graphen zu nehmen, welcher zum Teil schon vor trainiert worden ist. Im Zuge dessen werden nur mehr die letzten Ebenen des Graphen trainiert und auf die konkrete Aufgabe hin ausgelegt. Dies hat zur Folge, dass schneller ein verwendbarer Graphen vorhanden ist, dieser aber sehr wahrscheinlich nicht der Beste ist den es geben würde.

3.1.3 TensorBoard

TensorBoard stellt eine Erweiterung des TensorFlow-System dar, im Sinne einer Toolerweiterung. Jeder Graph kann in ein File Serialisiert werden, welches als Event-File bezeichnet wird. Dies hat zur Folge, dass dieser auch wieder geladen werden kann. Bei dieser Serialisierung werden alle Informationen des Graphen inklusive der Gewichtungen in die definierte Datei gespeichert. TensorBoard bietet nun die Möglichkeit diesen Graphen zu laden und diesen Visualisiert darzustellen. Zu den Graph-Informationen kann jeder Tensor mit gespeichert werden und als Diagramm visualisiert werden, mit einer zeitlichen Komponente. Dies ermöglicht es einem den Verlauf des Trainings zu analysieren. Aus einem Graphen können mehrere dieser Event-Files erzeugt werden sowie fixe Punkte definiert werden. Beim Laden eines

⁹Online Dokumentation: Training https://www.tensorflow.org/api_guides/python/train

```
1 import tensorflow as tf
2
3 with tf.name_scope("func"):
4     b = tf.Variable(tf.zeros([100]))
5     W = tf.Variable(tf.random_uniform([784,100],-1,1))
6     x = tf.placeholder(name="x")
7     relu = tf.nn.relu(tf.matmul(W, x) + b)
8
9 C = [...]
10 s = tf.Session()
11 for step in xrange(0, 10):
12     input = ...construct 100-D input array ...
13     result = s.run(C, feed_dict={x: input})
14
15 print step, result
```

Abbildung 3.6: TensorFlow Codefragment zur Namescope Verwendung in Graphen

Graphen in die TensorFlow sowie TensorBoard-Umgebung kann spezifiziert werden zu welchen Zeitpunkt geladen werden soll. Damit wird ermöglicht viele Trainingsdurchläufe zu durchlaufen und bei einer Verschlechterung der Präzision zu einem früheren Zustand zurück zu springen. Diese Tool ermöglichte es einem in das Verhalten eines Graphen ein wenig Einsicht zu nehmen und so die sogenannte Black Box zu durchleuchten.

Namensbereiche (*`tf.name_scope`*) stellen eine Hilfe für die Darstellung und die Lesbarkeit des visualisierten Graphen dar. Durch die Verwendung des Python-Schlüsselwortes *with* wird eine Ressource verwaltet und wieder freigegeben. In Verwendung mit *`tf.name_scope`* werden alle Operationen und Tensoren in diesem Block in der Visualisierung in einen benannten Block zusammengefasst.

Wie in der Codefragment 3.6 beschrieben werden die Tensoren und Operatoren *b*, *W*, *x*, *relu* in einen Block zusammen gefasst. In diesem Beispiel gibt es keinen Tensor, welcher in den Block übergeben wird, da die Daten in der Ausführung von außerhalb es System in dieses gelangen. Die Operation *relu* und der daraus resultierende Tensor bilden den Ausgang des Blockes. Diese Technik der Namensbereiche ermöglicht es einem den Graphen zu strukturieren, da nicht wie in *`tf.zeros([100])`* viele einzelne Knoten dargestellt werden, sonder abstrahiert werden und aber weiterhin einsehbar sind.

Graph bildet den Punkt zum Visualisieren des Graphen selbst. Hierbei werden aus dem Event-File alle Informationen zum Aufbau des Graphen geladen und visualisiert. Durch die Verwendung der Namensbereiche werden

Gruppen gebildet was dazu führt, dass die Gruppierungen möglicherweise in Ebenen sich widerspiegeln. Der dargestellte Graphen kann nach dem Einlesen und generieren interaktiv analysiert werden. So können Bereiche vergrößert und geöffnet werden und die definierten Tensoren betrachtet werden. Dieses Tool bietet zusätzliche Funktionalitäten, wie das Darstellen wo am meisten Rechenzeit benötigt wurde sowie auch welche Berechnung auf welchem Gerät ausgeführt worden ist. Alle diese zusätzlichen Funktionalitäten benötigen Daten, welche beim Erstellen des Graphen mit definiert werden müssen und auch mit in des Event-File serialisiert werden müssen.

Event repräsentiert den Bereich in welchem die Lernergebnisse dargestellt werden. Dies umfasst die Präzision sowie die Verluste. Das Ziel des Graphen ist im Grunde immer die Präzision zu erhöhen und die Verluste zu minimieren. Aus diesem Grund sollte sich die Genauigkeit an 1 annähern, außer die Definition dieser Berechnung liefert andere Werte oder besitzt einen anderen Grenzwert. Der Verlust sollte sich im Laufe des Trainings an 0 annähern, denn dadurch spiegelt sich die Fehlerquote ab. Dies hängt aber wieder von dem entwickelten Graphen ab und kann sich somit einem anderen Wert annähern.

Event bietet die Möglichkeit mehrere Graphen und ihre Eventdaten zu visualisieren. In diesem Fall werden alle gelesenen Events in einer Liste aufgelistet, in welcher ausgewählt werden kann welche Ausführung in den Diagrammen dargestellt werden sollen. In diesem Zuge können diese Diagramme zusammengeführt werden und so die Ergebnisse direkt verglichen werden. Dies hat den Vorteil, dass ein Netzwerk mit Hyperparameter automatisch getestet werden kann und jede Kombination ein eigenes Event-File erzeugt. Solche Testdurchläufe benötigen mehr Zeit, abhängig von den definierten Kombinationen an Parameter, muss $x * y * \dots$ alles durchgetestet werden. Die Informationen für die Lernrate sowie des Verlustes werden in diesem Fall am besten festgehalten. Dies wird ermöglicht indem die Tensoren, welche die Lernrate sowie den Verlust beinhalten, in die Methode *tf.summary.scalar* jeweils gefüttert wird. Bei jedem Schreibzyklus in das Event-File werden diese Informationen dann mit übernommen und stehen dann in TensorBoard zur Verfügung.

Distributions stellt eine weitere Funktionalität von TensorBoard dar. Diese Funktionalität war in den Versionen von 'r1.0' noch unter dem Punkt Histogramm. Im Allgemeinen werden Tensoren mit der Methode *tf.summary.histogram* wieder in das Event-File serialisiert. Das Ergebnis stellt eine Verteilung dar für die Werte die Tensor vorkommen. Dabei werden alle Werte auf eine Gaussian Glockenkurve projiziert. Das Diagramm repräsentiert auf der X-Achse die Anzahl der Schritte, die durchgeführt worden sind. Die Y-Achse gibt die konkreten Werte wieder, welche sich in dem Tensor über die Zeit




Abbildung 3.7: Verteilung der Werte in einem Tensor über die Zeit

befinden.

Im Diagramm 3.7) wird ein Tensor mit 100 Werten dargestellt. Dieser Tensor wurde mit einer Normalverteilung initialisiert, wobei die Standardabweichung bei 0.5 liegt und der Median zu Beginn bei 0.2 liegt, mit einer geringen Abweichung. Die Linien in diesem Diagramm (3.7) und ihre Einfärbungen präsentieren die Verteilung der Werte im beobachteten Tensor. Die Verteilung muss von unten nach oben gelesen werden, dabei ergibt die unterste Linie den minimalen Wert, der vorgekommen ist. Die nächste Linie besagt, dass 7% der Werte in dem Bereich zwischen dem geringsten und der zweiten Linie sich befinden, was inklusive des geringsten Wertes ist. Der nächste Bereich definiert, wie in einer Normalverteilung, dass bis zum Ende dieses Bereiches 16% darin befinden. Insgesamt sind dies 9 Markierungen mit 8 Bereichen, welche zusammen alle Werte im Tensor wieder spiegeln. Diese Folge an prozentualen Anteilen lautet wie folgt: *min*, 7%, 16%, 31%, 50%, 69%, 84%, 93%, *max*. Im Diagramm (3.8) ist diese Verteilung besser ersichtlich, zusätzlich befinden sich in der Abbildung 3.9 die Rohdaten der Diagramme.

Histogramm




Abbildung 3.8: Verteilung der Werte in dem Tensor zu dem Diagramm 3.7

```

1
2  -1.2645409, -0.92252451, -0.68004417, -0.63273954, -0.57005012,
3  -0.5477351, -0.54554129, -0.51146084, -0.50482351, -0.4872272,
4  -0.45631331, -0.44180638, -0.43258488, -0.38066232, -0.31675094,
5  -0.29567719, -0.27768314, -0.27437925, -0.19503899, -0.18343721,
6  -0.16653274, -0.13992153, -0.13946836, -0.12969615, -0.12044857,
7  -0.11908005, -0.06734778, -0.062724337, -0.032598898, -0.02885592,
8  0.006216079, 0.015204117, 0.018379062, 0.036883533, 0.041039094,
9  0.063002124, 0.068820029, 0.072805718, 0.11137276, 0.11735194,
10 0.12555882, 0.12613684, 0.13053563, 0.13633718, 0.17283598,
11 0.18271323, 0.18530971, 0.18671049, 0.24375655, 0.25207496,
12 0.27566099, 0.27588493, 0.27921408, 0.28581429, 0.29526407,
13 0.30613232, 0.32309669, 0.33705187, 0.34577289, 0.34687665,
14 0.37553167, 0.41834235, 0.43759531, 0.4376972, 0.45076531,
15 0.47984695, 0.49715465, 0.50634104, 0.51550949, 0.5168677,
16 0.53031796, 0.5579083, 0.56285316, 0.57165861, 0.59320259,
17 0.60513371, 0.61539149, 0.61814398, 0.63975775, 0.64333171,
18 0.67751783, 0.67795348, 0.68242437, 0.70252627, 0.70793462,
19 0.72128826, 0.80693412, 0.83029318, 0.83635086, 0.84400082,
20 0.84558558, 0.86151552, 0.95068389, 0.95598722, 1.0072051,
21 1.1837469, 1.1992682, 1.285683, 1.3168017, 1.3521272

```

Abbildung 3.9: Sortierter Ergebnistensor zum Verteilungsdiagramm 3.8 und 3.7

Kapitel 4

Facial Keypoints Detection

4.1 Ausgangssituation

4.2 Vorbereitung

4.2.1 Daten vorbereiten und normalisieren

4.2.2 Evaluation- und Errorfunktion

4.3 Neuronale Ebenen vorbereiten

4.4 Neuronale Ebenen verknüpfen

4.5 Trainieren

4.6 Validierungsergebnisse


Quellenverzeichnis

Literatur

- [1] Martin Abadi u. a. „Tensorflow: Large-scale machine learning on heterogeneous distributed systems“. *Google Research Whitepaper*, <http://research.google.com/pubs/archive/45166.pdf> (2015) (siehe S. 18, 19).
- [2] Christopher M Bishop. „Pattern recognition“. *Machine Learning* 128 (2006), S. 1–58 (siehe S. 9, 20).
- [3] Jeff Heaton. *Artificial Intelligence for Humans. Volume 3: Deep Learning and Neural Networks*. 2015 (siehe S. 3, 8–10, 14, 16).
- [4] Aristomenis S Lampropoulos und George A Tsirintzis. *Machine Learning Paradigms*. Springer, 2015 (siehe S. 3).
- [5] *TensorFlow*. URL: <http://www.tensorflow.org> (siehe S. 20).

Messbox zur Druckkontrolle

— Druckgröße kontrollieren! —



— Diese Seite nach dem Druck entfernen! —